

CAM168 – TRABALHO INDIVIDUAL SOBRE SMART SENSORS E SENsoRES VIRTUAIS

1. O que é inteligência para você?¹ (0,25 pto)
2. Faça um levantamento na literatura (e.g., *journals*, *magazines*, *conferences proceedings* etc.), em sites de jornais/notícias/revistas etc. de iniciativas de como embarcar uma Inteligência Artificial Geral² em um robô. (0,25 pto)
3. Procure na literatura 5 artigos que abordem o tema Smart Transducers (IEEE1451) para grandezas de seu interesse (e.g., temperatura, pressão, vazão, nível etc.) e publicados entre 2015 e 2025. Explique o que foi desenvolvido pelos autores. Coloque o trabalho no formato de um artigo científico do tipo ‘survey’³ seguindo o template disponibilizado na pasta Trabalhos/Trabalho Individual (conference-template-a4.docx). Liste as cinco referências que você consultou. (1,0 pto)

Sugestão: As principais informações de qualquer artigo geralmente se encontram no título, no resumo e nas conclusões. Ao ler esses três itens, o leitor tem uma boa ideia do que esperar daquele trabalho. A propósito, usualmente o leitor decidirá se lerá todo o artigo ou não com base na sua impressão a respeito desses três itens.

4. Considere o aparato ilustrado na figura à esquerda abaixo⁴. Um objeto está suspenso entre uma fonte de luz e duas células solares (LDRs). Variando-se a sua posição (y), variam-se as tensões v_1 e v_2 como apresentado na figura à direita. Projete uma rede neural do tipo Perceptrons de Múltiplas Camadas (PMC) - motor de um sensor virtual regressor - que determine a posição do objeto (em polegadas) a partir das tensões v_1 e v_2 (em volts) (ver **LDR_ball.xlsx**). Preze pela parcimônia. Apresente a análise crítica dos resultados obtidos. (0,5 pto)

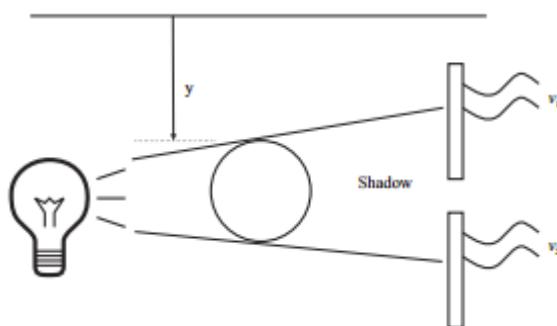


Figure 1 Position Sensor Arrangement

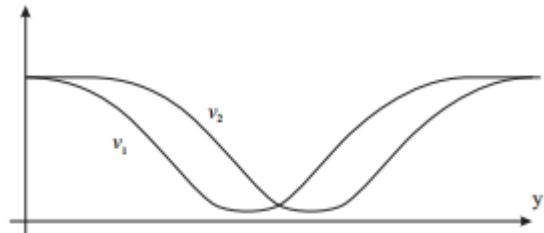


Figure 2 Example Solar Cell Outputs vs. Object Position

¹ Responder a esta pergunta sem consultar google, copilot, chatGPT e congêneres.

² Artificial General Intelligence (AGI)

³ Exemplo de ‘survey’ presente na pasta IEEE1451-Smart Transducers/artigos: “A. Kumar, V. Srivastava, M. K. Singh and G. P. Hancke, “Current Status of the IEEE 1451 Standard-Based Sensor Applications,” in IEEE Sensors Journal, vol. 15, no. 5, pp. 2505-2513, May 2015, doi: 10.1109/JSEN.2014.2359794.

⁴ Questão elaborada a partir de <http://hagan.okstate.edu/NNDesign.pdf>

5. A partir da análise de um processo de destilação fracionada de petróleo observou-se que determinado óleo poderia ser classificado em duas classes de pureza {C1 e C2}, mediante a medição de três grandezas { x_1 , x_2 e x_3 } que representam algumas das propriedades físico-químicas do óleo. Para tanto, utilizar-se-á um PMC para executar a classificação automática dessas duas classes. Assim, baseado nas informações coletadas do processo, formou-se o conjunto de treinamento disponibilizado em **dadosTrafos.xlsx**, tomado por convenção o valor -1 para óleo pertencente à classe C1 e o valor +1 para óleo pertencente à classe C2. (0,5 pto)

Daí, pede-se:

- Execute dois treinamentos para a rede PMC, inicializando o vetor de pesos em cada treinamento com valores aleatórios entre 0 e 1, de modo que os vetores de pesos iniciais não sejam iguais.
- Registre, sob a forma de uma tabela ou de um quadro, todos os pesos e bias obtidos a partir das duas redes treinadas. Registre também o número de épocas necessárias em cada um dos treinamentos e explique por que o número varia a cada etapa de treinamento. Por fim, explique o critério de parada empregado no algoritmo de treinamento.
- Após o treinamento dos PMC, aplique-os na classificação automática de novas amostras de óleo presentes no quadro abaixo⁵, indicando-se nele os resultados das saídas (Classes) referentes aos dois processos de treinamento realizados no item a.

Amostra	x_1	x_2	x_3	y (T1)	y (T2)
1	-0.3565	0.0620	5.9891		
2	-0.7842	1.1267	5.5912		
3	0.3012	0.5611	5.8234		
4	0.7757	1.0648	8.0677		
5	0.1570	0.8028	6.3040		
6	-0.7014	1.0316	3.6005		
7	0.3748	0.1536	6.1537		
8	-0.6920	0.9404	4.4058		
9	-1.3970	0.7141	4.9263		
10	-1.8842	-0.2805	1.2548		

ANEXO – Conjunto de Treinamento (ver aba tab_treinamento de **dadosTrafos1.xlsx**).

Amostra	x_1	x_2	x_3	d
01	-0.6508	0.1097	4.0009	-1.0000
02	-1.4492	0.8896	4.4005	-1.0000
...
29	2.0149	0.6192	10.9263	-1.0000
30	0.2012	0.2611	5.4631	1.0000

⁵ Ver aba tab_teste de **dadosTrafos1.xlsx**.

6. Valendo-se da base de dados reais referente a uma série de carga elétrica (dados de Potência Ativa (PA)) de uma concessionária de energia elétrica do Rio de Janeiro que se encontra no arquivo `carga_eletrica.xlsx`, desenvolva um previsor neural que receba como entradas pelo menos as medições de PA nos instantes k-1, k-2 e k-24 (i.e. PA(k-1), PA(k-2) e PA(k-24)) e que disponibilize na saída a potência ativa na hora corrente k (i.e. PA(k)). O previsor deverá realizar previsões recursivas de 1 a 24 passos à frente (i.e., de 1 a 24 horas à frente). Realizar testes-cegos dos previsores candidatos considerando como índice de desempenho o ‘Mean Absolute Percentage Error’ (MAPE). (0,5 pto)

$$MAPE = \left(\frac{1}{n} \sum_{i=1}^n \frac{|Pot.Medida_{(i)} - Pot.Prevista_{(i)}|}{|Pot.Medida_{(i)}|} \right) \cdot 100\%$$

Uma vez terminado todo o trabalho de simulação e de desenvolvimento, documentá-lo e enviá-lo para `reis@ufop.edu.br` no formato pdf até **27/02/2026**. Os códigos desenvolvidos **devem** ser disponibilizados via GitHub ou Colab.